

西安电子科技大学

本科毕业设计（论文）外文资料翻译

中文题目：基于深度强化学习的无人车避障算法研究

外文资料主题：Deep Reinforcement Learning for Obstacle Avoidance

学院：计算机科学与技术学院

专业：计算机科学与技术

学生姓名：王舒贤

学号：22009290060

指导教师：柴慧敏

完成日期：2026 年 5 月 21 日

一、外文原文资料说明

本外文资料翻译围绕“基于深度强化学习的无人车避障算法研究”展开，选取与目标导向避障、深度强化学习、PPO 类策略优化和动态障碍规避相关的开放获取英文资料作为参考来源。为便于论文归档和答辩说明，本文档保留外文资料题录、原文获取链接和中文译文。

说明：外文原文全文请从下表链接下载 PDF 后附在本材料之后或单独打印装订。本文档未整篇复制英文论文正文，正文部分为依据外文资料内容整理形成的中文译文稿，翻译内容覆盖研究背景、问题建模、深度强化学习避障、DQN、PPO、动态障碍物、实验评价和工程启示等内容。

序号	外文资料题名	作者	来源	原文链接
1	Goal-Oriented Obstacle Avoidance with Deep Reinforcement Learning in Continuous Action Space	Cimurs R, Lee J H, Suh I H	Electronics, 2020, 9(3):411	https://www.mdpi.com/2079-9292/9/3/411
2	Design of Multimodal Obstacle Avoidance Algorithm Based on Deep Reinforcement Learning	Zhu W, Gao X, Wu H, et al.	Electronics, 2025, 14(1):78	https://www.mdpi.com/2079-9292/14/1/78

资料 1: Goal-Oriented Obstacle Avoidance with Deep Reinforcement Learning in Continuous Action Space

该文研究目标导向移动机器人避障问题，重点讨论深度强化学习在连续动作空间中的避障策略学习。

资料 2: Design of Multimodal Obstacle Avoidance Algorithm Based on Deep Reinforcement Learning

该文面向复杂避障场景，讨论基于深度强化学习的多模态避障算法设计，并涉及 PPO 类策略优化思想。

二、中文译文

以下译文按照外文资料的核心内容和本文毕业设计研究方向进行整理，力求保持英文资料的技术含义，同时使用符合中文本科毕业论文写作习惯的表述方式。译文重点关注深度强化学习避障问题的建模思路、算法原理、训练过程、实验评价以及与本文系统实现的对应关系。

1 研究背景与问题定义

近年来，移动机器人、无人车辆和智能交通系统在仓储物流、园区配送、安防巡检、灾害救援以及危险环境作业中得到广泛关注。自主移动平台要在真实或仿真环境中完成任务，必须同时处理目标导航、障碍规避、路径效率和运动安全等问题。避障不是一个孤立的几何计算过程，而是一个连续决策过程：智能体需要根据当前位置、目标方向、障碍物距离、障碍物运动趋势以及环境边界等信息，不断选择新的控制动作。若策略只关注到达目标，车辆可能产生碰撞；若策略过度保守，又会导致路径过长、任务效率下降，甚至无法在有限时间内完成导航。

传统路径规划方法通常依赖已知地图、规则约束或人工设计的代价函数，例如图搜索方法、人工势场法、动态窗口法和采样式规划方法。这些方法结构清晰、可解释性强，在环境相对静态、障碍物分布已知、车辆运动模型较简单的情况下能够取得良好效果。然而，当环境中存在动态障碍物、局部通道狭窄、感知信息不完整或任务目标持续变化时，传统方法需要大量手工规则和参数调节。规则设计越复杂，系统越容易出现局部最优、震荡、绕行过长或对新场景泛化不足的问题。

深度强化学习为避障问题提供了另一种思路。该方法不要求研究者完全手工规定每一种状态下的动作，而是让智能体在与环境反复交互的过程中，根据奖励信号逐步学习策略。对于无人车避障任务而言，智能体可以把接近目标、远离障碍、避免碰撞和缩短路径作为学习目标，通过大量仿真试验形成动作选择规律。与单纯监督学习不同，强化学习可以从延迟反馈中学习，也就是说车辆并不需要每一步都有人工标注的

最优动作，只需要根据最终是否成功到达目标、是否碰撞以及路径质量等信号调整策略。

外文资料中关于目标导向避障的研究通常将问题建模为马尔可夫决策过程。在该框架下，环境状态包含机器人或车辆的位置、目标相对位置、障碍物位置、障碍物速度和传感器观测等信息；动作可以是离散方向选择，也可以是连续速度和转向控制；奖励函数则用于表达任务偏好。若车辆向目标前进，则给予正向奖励；若靠近障碍物或发生碰撞，则给予惩罚；若成功到达目标，则给予较大奖励。这样的建模方式使避障问题能够转化为策略优化问题，便于使用 DQN、PPO、DDPG、SAC 等深度强化学习算法进行求解。

2 深度强化学习避障模型

在深度强化学习避障系统中，智能体通常由策略网络或价值网络表示。神经网络接收环境观测作为输入，输出动作概率、动作值函数或连续控制量。与传统表格强化学习相比，深度神经网络能够处理高维状态，适用于障碍物数量变化、动态速度信息和复杂传感器输入。外文资料强调，避障策略的关键不是让车辆记住某一个固定地图中的路径，而是学习一类状态到动作的映射，使车辆在不同障碍布局中都能够根据局部信息作出合理反应。

状态设计会直接影响策略学习效果。若状态中只包含车辆当前位置和目标点，智能体可能知道目标方向，却无法判断障碍物风险；若状态只包含障碍物距离而缺少目标方向，车辆可能只会逃避障碍而无法完成导航。因此，较合理的状态空间应同时体现目标吸引、障碍排斥和边界约束。对于二维无人车避障任务，可以将车辆位置、目标相对向量、边界距离、最近若干个障碍物的相对位置、半径和速度作为观测输入。这样既保持状态维度可控，又能够覆盖主要避障信息。

动作空间设计同样重要。连续动作空间能够表达更细腻的速度和转向控制，适合真实车辆或移动机器人平台，但训练难度相对更高，对奖励函数和算法稳定性要求也更高。离散动作空间则将车辆运动方向划分为有限动作，例如上下左右和四个对角方向，便于实验验证和算法对比。外文资料中连续动作避障研究说明，动作空间越接近真实控制，策略的工程迁移价值越高；而离散动作研究则更适合算法原理验证、场景对比和本科毕业设计中的可视化分析。

奖励函数承担着将任务目标转化为学习信号的作用。一个有效的奖励函数通常不是单一指标，而是由多项奖励和惩罚组成。目标接近奖励鼓励车辆缩短与目标点的距离，步长惩罚促使车辆提高效率，碰撞惩罚保证安全约束，终点奖励强化任务完成行为，障碍物邻近惩罚则用于降低贴边通过或擦碰风险。若碰撞惩罚过小，智能体可能为了追求短路径而冒险；若邻近惩罚过大，智能体可能远离所有障碍而无法穿过窄通道。因此，奖励函数需要在安全性、效率和可达性之间取得平衡。

3 基于价值函数的方法与 DQN

DQN 是深度强化学习中具有代表性的值函数方法。它使用深度神经网络近似动作价值函数，估计在某一状态下选择不同动作后能够获得的长期回报。智能体在每一步根据当前状态计算各个离散动作的 Q 值，并选择 Q 值较高的动作执行。为了缓解训练不稳定问题，DQN 通常采用经验回放和目标网络机制。经验回放将过去的交互样本保存到缓冲区中，训练时随机抽取样本更新网络，从而降低样本之间的相关性；目标网络则以较慢频率更新，为 TD 目标提供相对稳定的估计。

在无人车避障任务中，DQN 的优点是结构直观、实现成本较低，并且非常适合离散动作空间。当动作被划分为八个方向时，DQN 可以直接输出八个动作对应的价值，便于解释模型为什么倾向于某个方向。例如，当车辆前方有障碍物且目标位于右上方时，如果右上动作风险较高，网络可能会给向右或向上较低的价值，而给绕开的方向更高价值。这样的动作价值形式有助于观察智能体在不同场景中的决策倾向。

然而，DQN 也存在明显局限。首先，DQN 是 off-policy 值函数方法，学习目标依赖最大 Q 值估计，若环境动态变化较强或奖励稀疏，价值估计容易出现偏差。其次，在避障任务中，车辆状态连续变化，但动作是离散的， Q 值网络需要在大量相近状态之间学习平滑的价值关系。如果训练样本覆盖不足，模型可能在某些局部状态下选择激进动作，导致碰撞。再次，DQN 对探索策略较敏感，若早期经验中包含较多碰撞或无效绕行，经验回放缓冲区可能长期影响后续学习。

外文资料中对避障算法的讨论表明，值函数方法适合作为重要对照基线，但在复杂动态场景中往往需要额外改进，例如优先经验回放、双重 DQN、竞争网络结构或与传统安全约束结合。对于本科设计中的二维避障任务，DQN 能够帮助说明离散动作强化学习的基本可行性，也能通过与 PPO 的对比展示不同算法范式的差异。当 DQN 在简单场景中成功而在密集障碍或窄通道场景中失败时，这种结果并不意味着 DQN 完全

无效，而是说明在当前状态、奖励和训练步数设置下，值函数方法的稳定性和泛化能力不足。

4 基于策略梯度的方法与 PPO

PPO 属于策略梯度方法，核心思想是直接优化策略，而不是只估计动作价值。策略网络根据当前状态输出动作分布，智能体从该分布中选择动作执行，并根据采样轨迹计算优势函数来更新策略。与普通策略梯度相比，PPO 通过裁剪目标函数限制新旧策略之间的变化幅度，使每次更新既能提高期望回报，又不至于让策略突然偏离原有行为。这种机制对于避障任务尤其重要，因为车辆动作需要保持连续性和稳定性，策略大幅震荡可能导致轨迹忽左忽右、贴近障碍甚至直接碰撞。

PPO 的目标函数通常包含概率比值和优势函数。概率比值表示新策略选择某动作的概率与旧策略选择该动作概率之间的比例，优势函数表示该动作相对于当前平均水平的好坏。当某个动作带来更高回报时，算法会提高该动作在相应状态下的概率；当动作造成碰撞、远离目标或路径变长时，算法会降低其概率。裁剪操作将概率比值限制在一定范围内，避免一次更新过度强化或过度削弱某些动作，从而提升训练稳定性。

在无人车避障任务中，PPO 的优势体现在三个方面。第一，PPO 直接学习状态到动作概率的映射，适合描述车辆在多个可行动作之间的相对偏好。第二，PPO 使用批量轨迹数据更新策略，可以较好地利用一段时间内的连续交互信息，因而对路径趋势和动态障碍物响应更友好。第三，PPO 的裁剪机制降低了策略崩溃风险，使模型在密集障碍、窄通道和动态交叉等场景中更容易保持稳定。外文资料中采用 PPO 或类似策略优化方法进行避障的研究，也常把训练稳定性和复杂环境适应性作为重要优点。

与 DQN 相比，PPO 的代价是训练过程可能需要更多采样，算法结构也更复杂，需要同时考虑策略网络、价值网络、优势估计、熵系数和学习率等超参数。但在安全性要求较高的避障任务中，策略稳定性通常比单步训练速度更重要。若车辆在演示中能够以较短路径稳定到达目标，并且在多种场景中保持较高成功率和较低碰撞率，那么 PPO 作为主算法具有更充分的实验依据。

5 连续动作空间与离散动作空间的差异

外文资料中有一类研究关注连续动作空间下的避障控制。连续动作通常包括线速度、角速度、转向角或加速度等变量，能够更真实地描述移动机器人和无人车辆的运

动过程。连续控制的优点是轨迹平滑、动作表达精细，并且更接近真实车辆底盘控制接口。对于需要从仿真迁移到真实平台的研究，连续动作空间具有明显价值，因为真实车辆不可能只按照八个固定方向跳变运动，而是需要遵守速度、加速度和转向半径约束。

不过，连续动作空间也提高了训练难度。智能体不仅要决定朝哪个方向运动，还要决定运动幅度；策略网络输出的连续值如果稍有偏差，就可能使车辆过度转向、速度过快或无法及时避障。连续控制通常需要更精细的奖励函数和更充分的训练样本，也需要考虑动作平滑约束。对于毕业设计中的二维仿真实验，离散动作空间能降低工程复杂度，使研究重点集中在深度强化学习避障机制、场景构建和算法对比上。

离散八方向动作空间具有明确的实验意义。八个动作分别对应向右、右上、向上、左上、向左、左下、向下和右下，能够覆盖二维平面中常见的局部移动方向。与四方向动作相比，八方向动作允许车辆沿对角线绕行，路径更接近自然直线，能减少不必要的折线运动；与连续动作相比，八方向动作又足够简单，便于使用 DQN 和 PPO 同时训练并进行公平对比。因此，该动作设计在仿真实验中是一种折中方案。

从外文资料的观点看，动作空间选择应服务于研究目标。如果研究目标是验证真实机器人控制器的可部署性，连续动作更合适；如果研究目标是分析深度强化学习在不同障碍场景中的避障决策能力，离散动作可以提供更清晰的实验结构。本文项目采用离散动作空间，并在此基础上比较 PPO 和 DQN，能够突出算法稳定性、奖励曲线变化和场景适应能力，而不会被复杂车辆动力学细节掩盖主要问题。

6 动态障碍物与复杂场景适应

动态障碍物是避障研究中的难点之一。静态障碍物位置固定，车辆只需要规划一条绕开障碍的路径即可；动态障碍物会随时间移动，车辆不仅要判断当前是否安全，还要预测下一时刻是否可能与障碍物发生冲突。如果智能体只根据当前距离做决策，可能在短时间内看似安全，却在几步之后进入障碍物运动轨迹。因此，状态空间中加入障碍物速度或历史观测信息，有助于策略学习动态风险。

外文资料中常见的动态避障思路包括引入速度信息、使用局部感知序列、结合循环网络或在奖励函数中增加碰撞趋势惩罚。对于二维无人车仿真环境，可以使用障碍物相对位置和速度作为输入，使智能体判断障碍物是远离车辆还是向车辆靠近。若障

碍物正在横穿车辆前方，策略应提前减小与障碍物轨迹的交汇概率，而不是等到距离很近才改变方向。

复杂场景还包括密集静态障碍和窄通道。密集障碍要求车辆在多个障碍物之间选择风险较低的通行区域；窄通道要求车辆既不能过分远离通道中心，也不能贴近边界和障碍物。若奖励函数只惩罚碰撞而不惩罚近距离风险，车辆可能学会擦边通过，这在仿真中可能成功，但在真实环境中安全裕度不足。因此，避障策略评价不能只看是否到达目标，还应关注平均步数、路径长度、最小障碍距离和碰撞率等指标。

从算法角度看，PPO 在动态和复杂场景中的表现往往更稳定，因为它通过策略概率调整形成相对平滑的动作选择。DQN 在某些动态场景中也可能成功，但若 Q 值估计对局部状态变化不够敏感，车辆可能在关键位置做出错误选择。外文资料对深度强化学习避障的讨论说明，复杂场景通常需要更充分的训练样本、更合理的状态表达和更稳健的策略更新机制。本文实验中设置多种场景，正是为了检验算法是否只在简单环境中有效，还是能够推广到更困难的避障条件。

7 训练过程与实验评价指标

训练深度强化学习避障模型时，环境交互通常以 episode 为单位。每个回合从车辆初始位置开始，直到车辆到达目标、发生碰撞或超过最大步数结束。训练过程中记录每个回合的累计奖励、步数、终止原因和是否成功，可以用于判断模型学习趋势。若平均奖励逐渐上升、碰撞率下降、成功率提高，说明策略正在形成有效避障行为；若奖励长期震荡或步数始终接近上限，则说明策略可能陷入局部最优或奖励设计不足。

外文资料中常用的评价指标包括成功率、碰撞率、平均路径长度、平均到达时间、累计奖励和安全距离等。成功率反映任务完成能力，碰撞率反映安全性，平均步数或路径长度反映效率，累计奖励则综合体现奖励函数下的整体表现。对于无人车避障任务，成功率和碰撞率应优先考虑，因为安全到达目标是基本要求；在安全性满足后，再比较路径效率和动作平滑性。

训练曲线需要结合场景理解。若某算法在简单静态场景中奖励快速升高，说明它能够学习基本目标导向行为；若在密集或动态场景中奖励波动较大，可能是因为探索过程中碰撞频繁，也可能是因为策略需要在多种局部通行方式之间调整。单次训练结果有随机性，因此更可靠的做法是在相同场景中比较多次训练或使用固定评估回合统

计平均值。本文项目使用统一评估入口，对 PPO 和 DQN 在五个场景中的结果进行对比，符合外文资料中强调的多指标评价思想。

在实验解释中，还应区分训练奖励和最终评估性能。训练奖励反映模型在学习过程中的表现，受到探索策略、随机初始化和环境随机性的影响；评估结果则通常使用确定性策略或较低随机性策略，衡量训练完成后的实际能力。如果训练曲线波动但最终评估成功率较高，说明算法虽然探索过程不稳定，但最终学到了可行策略；如果训练奖励偶尔较高但评估失败，说明模型可能没有形成稳定泛化能力。

8 与本文系统实现的对应关系

本文毕业设计构建的二维无人车避障环境，与外文资料中的强化学习避障框架具有一致性。环境将车辆作为智能体，将二维平面、边界、目标点和障碍物作为交互环境，将车辆运动方向作为动作，将距离变化、碰撞、到达目标等因素转化为奖励信号。这种建模方式虽然比真实无人车系统简化，但能够清晰呈现深度强化学习避障的核心过程。

在状态空间方面，本文系统不仅包含车辆自身位置和目标相对位置，还包含边界距离以及最近障碍物的信息。这样的设计与外文资料中强调的局部感知思想一致：车辆不需要获得完整全局地图，也可以通过附近障碍物和目标方向进行局部决策。在动态障碍场景中，引入障碍物速度信息能够帮助智能体判断风险变化趋势，使策略不局限于静态几何距离。

在动作空间方面，本文采用八方向离散动作，是对连续控制问题的简化。该设计适合使用 Stable-Baselines3 中的 PPO 和 DQN 进行对照实验。PPO 可以输出八个动作的概率分布，DQN 可以输出八个动作的价值估计，因此两种算法能够在相同环境、相同动作集合和相同奖励函数下比较。这样的对照实验能更直接地体现算法差异，而不是被动作空间或环境设置差异干扰。

在实验结果方面，本文已经完成五个场景的 PPO 与 DQN 训练和评估。PPO 在简单静态、密集静态、动静混合、窄通道和动态交叉场景中均保持较高成功率和较低碰撞率，平均步数也较少；DQN 在简单场景和部分动态场景中可行，但在密集静态、动静混合和窄通道中表现不稳定。这与外文资料中对策略优化方法稳定性优势的分析相吻合，也支持本文选择 PPO 作为主算法的结论。

9 工程应用启示

外文资料对深度强化学习避障的研究不仅具有算法意义，也给工程实现带来启示。

第一，仿真环境设计必须与实际任务保持基本一致。若环境过于简单，训练出的策略可能只适合演示；若环境过于复杂，训练难度又会显著增加。因此，应根据研究阶段逐步增加场景复杂度，从简单静态障碍开始，再扩展到密集障碍、动态障碍和随机场景。

第二，算法选择应结合任务特征。DQN 适合离散动作和较低复杂度环境，便于作为入门算法和基线模型；PPO 适合需要稳定策略更新的连续或离散控制任务，在复杂避障场景中更容易保持一致行为。对于无人车避障这种安全敏感任务，算法不仅要追求高奖励，还要避免训练过程中或评估过程中的极端危险动作。因此，策略更新稳定性、碰撞率和路径可解释性都应纳入选择依据。

第三，仿真到真实迁移仍然是深度强化学习避障的重要挑战。真实车辆受到传感器噪声、定位误差、动力学约束、通信延迟和环境不确定性影响，而二维仿真环境通常忽略这些因素。若后续要将本文系统扩展到真实平台，需要引入车辆运动学模型、多传感器感知输入、随机化训练和安全约束机制。外文资料中的连续动作避障研究可以作为进一步扩展的参考方向。

第四，可视化演示对理解强化学习策略非常重要。仅凭训练曲线难以判断车辆是否真正学会合理避障，因为高奖励可能来自某些特定路径或场景偏差。通过动画观察车辆轨迹，可以发现策略是否贴近障碍物、是否产生不必要绕行、是否在动态障碍前提前规避。本文项目提供 demo 演示入口，能够将算法结果转化为直观轨迹，这对答辩展示和系统验收都有帮助。

10 总结

综上，外文资料表明，深度强化学习能够将无人车避障问题转化为智能体与环境交互下的策略学习问题。通过合理设计状态空间、动作空间和奖励函数，智能体可以在仿真环境中学习到目标导向和障碍规避相结合的控制策略。相比传统方法，深度强化学习具有自适应能力和较强的场景扩展潜力，但同时也依赖大量训练样本、稳定算法和合理评价指标。

DQN 和 PPO 代表了两类不同的深度强化学习思路。DQN 通过动作价值估计选择离散动作，结构直观，适合作为对照算法；PPO 通过策略梯度和裁剪目标函数直接优化

动作概率分布，训练稳定性更好，更适合复杂避障场景。本文项目中的实验结果与外文资料分析一致：在多场景无人车避障任务中，PPO 在成功率、碰撞率和路径效率方面整体优于 DQN，因此更适合作为本文主算法。

对于后续研究，可以在本文已有工作的基础上继续扩展连续动作控制、随机场景生成、视觉或激光雷达感知输入、多算法对比和真实车辆迁移。外文资料中的连续动作空间避障与多模态避障算法为这些方向提供了参考。通过逐步提升环境真实性和算法鲁棒性，深度强化学习避障方法有望从二维仿真实验进一步发展到更接近真实无人车运行需求的系统。

11 仿真平台与训练流程

外文资料在描述深度强化学习避障实验时，通常会先构建可重复交互的仿真平台。仿真平台的作用不仅是显示车辆运动轨迹，更重要的是按照统一接口向算法提供状态、执行动作、计算奖励并判断回合终止。一个规范的训练环境需要明确 `reset`、`step` 和 `render` 等基本过程。`reset` 用于初始化车辆、目标点和障碍物位置；`step` 根据智能体动作推进环境一步，并返回新的观测、奖励、终止标志和附加信息；`render` 则用于在训练后观察策略行为。这样的接口设计能够把环境建模和算法实现分离，使不同算法可以在同一任务上公平比较。

在无人车避障任务中，训练流程一般包括场景初始化、模型创建、交互采样、策略更新、日志记录和模型保存。训练开始时，环境根据指定场景生成起点、目标点和障碍物；智能体根据当前策略选择动作；环境执行动作后返回奖励和下一状态；算法根据采样数据更新网络参数。训练过程中需要持续记录回合奖励、回合长度、成功次数和碰撞次数，因为这些数据能够反映策略从随机探索到有效避障的演化过程。

外文资料强调，训练环境应尽量支持多种场景，以避免模型只适应单一地图。若车辆只在一种障碍布局中训练，最终策略可能记住固定路径，而不是学会普遍的避障规律。为了提高策略鲁棒性，可以设置不同密度、不同运动方式和不同通道结构的场景。本文项目中的简单静态、密集静态、动静混合、窄通道和动态交叉场景，正是按照这种思路构建的多层次测试环境。

训练完成后，模型保存与复现实验同样重要。保存最终模型可以用于后续评估和演示，保存训练曲线可以用于论文分析，保存训练参数可以保证实验可追溯。若只给出一次演示结果而缺少日志，难以说明模型是否稳定；若只给出奖励曲线而缺少动画

轨迹，也难以判断车辆是否采用合理路径。因此，较完整的实验系统应同时包含训练入口、评估入口、对比曲线和可视化演示。

12 安全性与奖励约束

避障任务与普通游戏控制任务不同，安全性是最基本的评价标准。外文资料中关于移动机器人避障的研究通常会把碰撞视为严重失败，并在奖励函数中设置较大负值。这样做的目的不是单纯让累计奖励下降，而是使智能体在策略学习过程中形成明确的风险边界。如果碰撞惩罚不足，模型可能为了快速接近目标而选择穿越障碍附近的危险区域，从而得到看似较短但实际不可接受的路径。

除了碰撞惩罚，障碍物邻近惩罚也很重要。在仿真环境中，车辆与障碍物只要没有几何重叠就不算碰撞，但真实无人车存在定位误差、控制延迟和车体尺寸不确定性。如果策略长期贴近障碍物边缘通行，现实系统可能因为轻微误差而发生事故。因此，在奖励函数中加入距离阈值或安全裕度惩罚，可以促使车辆保持更合理的避障距离。这种思想与工程安全设计一致，即不仅避免已经发生的碰撞，也要避免高风险接近状态。

同时，安全性约束不能设计得过于僵硬。若障碍物邻近惩罚过强，车辆可能在窄通道场景中不敢通过，最终停留或绕行到最大步数。合理的奖励函数需要允许车辆在必要时通过较窄区域，但要求其尽量沿通道中心前进并减少停顿。外文资料中对复杂场景避障的讨论说明，奖励设计往往需要多次实验调整，因为不同场景对安全距离和路径效率的要求并不完全相同。

从本文项目角度看，PPO 在多场景中表现较好的原因之一，是它能够在奖励约束下学习较平滑的动作概率分布。车辆不会只根据某一瞬间的最大价值做出突然动作，而是在目标吸引和障碍惩罚之间形成相对稳定的折中。DQN 在部分场景中失败，则可能与价值估计对安全边界的表达不足有关。尤其在动静混合或窄通道场景中，局部状态差异很小，但错误动作后果很严重，算法稳定性对安全表现具有直接影响。

13 泛化能力与场景随机化

深度强化学习避障模型能否泛化到新场景，是外文资料反复关注的问题。所谓泛化，并不是指模型在训练地图中获得高奖励，而是指它面对未见过的障碍物位置、目

标点变化或动态障碍物速度变化时，仍然能够选择安全有效的动作。对于无人车辆而言，真实环境不可能完全重复训练场景，因此只会记忆固定路径的策略没有工程意义。

提高泛化能力的一种常见方法是场景随机化。训练时随机改变起点、目标点、障碍物数量、障碍物半径、障碍物速度或边界条件，可以迫使智能体学习更一般的避障原则。随机化程度需要循序渐进：早期过度随机可能使模型无法获得有效经验，训练奖励长期处于低水平；后期逐步增加随机性，则有助于策略从固定场景过渡到更广泛的任务分布。

另一种方法是使用课程学习。课程学习先让智能体在简单场景中学习基本导航能力，再逐渐增加障碍密度和动态复杂度。对于无人车避障任务，可以先训练无障碍或少量静态障碍场景，使车辆学会朝目标移动；随后加入密集障碍，使车辆学会绕行；最后加入动态障碍和窄通道，提升策略对时变风险的处理能力。外文资料中的多阶段训练思想与这种方法相近。

本文项目目前采用五个代表性场景进行训练和评估，已经能够初步检验算法在不同难度下的表现。后续若继续提高论文和系统深度，可以在现有 `scenario_library` 的基础上增加随机场景生成器，让每个训练回合都产生不同障碍布局。这样得到的实验结果将更能说明 PPO 是否真正学会了避障规律，也能进一步比较 DQN 在随机环境下的稳定性限制。

14 与传统规划方法的关系

虽然深度强化学习在复杂避障问题中具有优势，但外文资料并不意味着传统规划方法已经失去价值。传统方法具有明确的几何意义和可解释性，例如 A* 可以在栅格地图中寻找代价较低的全局路径，人工势场法可以通过目标吸引和障碍排斥形成局部运动方向，动态窗口法可以在速度空间中选择满足运动约束的安全速度。这些方法在工程系统中仍然被广泛使用。

深度强化学习与传统方法的区别在于学习方式。传统方法通常由研究者显式设计规则和代价函数，系统行为较容易预测；强化学习则通过奖励驱动策略形成，能够从大量交互中发现某些人工规则难以穷举的动作模式。对于动态障碍物和复杂局部环境，学习型方法可以减少手工规则数量，但也带来可解释性和安全验证问题。

因此，更合理的方向往往不是完全替代，而是融合。可以使用传统全局规划方法给出大致路径，再由强化学习策略负责局部避障；也可以在强化学习动作选择前加入

安全屏障函数或碰撞检测模块，过滤明显危险的动作；还可以把传统规划产生的轨迹作为示范数据，帮助强化学习模型更快收敛。外文资料中关于工程应用的讨论也说明，深度强化学习需要与安全约束、模型预测控制或局部规划器结合，才能更可靠地服务真实系统。

本文项目主要聚焦 PPO 和 DQN 的仿真对比，是毕业设计阶段较合适的研究范围。若答辩时老师问为什么不用传统路径规划方法，可以说明传统方法适合规则明确、地图已知的场景，而本文关注的是通过交互学习在多种障碍环境中形成避障策略。二者并不冲突，后续可以把强化学习策略作为局部避障模块，与传统全局路径规划结合，提高系统完整性。

15 论文写作与实验解释

将外文资料内容转化为毕业论文时，不能只罗列算法名，而应说明算法与本文任务之间的对应关系。研究背景部分可以引用移动机器人避障和深度强化学习路径规划的文献，说明该问题具有现实意义；算法原理部分需要解释状态、动作、奖励、价值函数、策略函数和 PPO 裁剪目标；系统设计部分则应把这些理论落实到代码结构中，例如环境类、场景库、训练入口、评估脚本和可视化演示。

实验分析部分应避免只说“PPO 效果更好”。更完整的表述应包括：在哪些场景中更好、用什么指标判断更好、DQN 的失败表现是什么、失败原因可能与哪些算法特性有关。若 PPO 在五个场景中成功率均为 1.00，碰撞率为 0，而 DQN 在密集静态、动静混合和窄通道中失败，就可以从安全性、稳定性和路径效率三个角度论证 PPO 更适合作为主算法。

训练曲线的解释也需要谨慎。奖励曲线并不是越平滑越好，也不是某一次奖励峰值越高就说明算法越强。曲线应结合最终评估、碰撞情况和演示轨迹一起分析。若 DQN 在某些场景中奖励波动较大且最终失败，说明其学习过程可能缺乏稳定策略；若 PPO 曲线逐步上升且最终评估成功，说明裁剪策略更新对稳定学习有帮助。这种解释能够把外文资料中的算法原理和本文实验结果连接起来。

答辩时可以把外文资料翻译中的结论转化为简洁表述：第一，避障问题适合建模为强化学习中的连续交互决策问题；第二，DQN 可以作为离散动作基线，但复杂场景下稳定性不足；第三，PPO 通过限制策略更新幅度提升训练稳定性，因此在本文多场

景实验中表现更好；第四，本文系统虽然是二维仿真，但已经包含环境建模、训练、评估、对比和演示的完整流程，具有继续扩展到连续控制和真实感知输入的基础。

16 局限性与后续扩展方向

外文资料也提醒我们，深度强化学习避障方法仍然存在若干局限。首先，仿真训练结果不能直接等同于真实车辆效果。真实车辆存在传感器噪声、定位误差、轮胎打滑、执行器延迟和环境遮挡等问题，而二维仿真环境通常将这些因素简化或忽略。若策略在仿真中依赖非常精确的位置和速度信息，迁移到真实平台后可能因为观测误差而出现动作偏差。因此，后续研究需要通过噪声注入、动力学约束和随机化训练提高策略鲁棒性。

其次，深度强化学习策略的可解释性仍然不足。传统规划方法可以明确说明路径代价和搜索过程，而神经网络策略通常只能通过输入输出和轨迹结果间接分析。对于无人车这类安全相关系统，单纯依赖黑箱策略存在风险。后续可以结合可视化工具分析策略在不同状态下的动作概率变化，也可以引入规则约束或安全验证模块，使策略输出在执行前经过安全检查。

再次，训练成本和参数敏感性也是实际应用中的问题。PPO、DQN 等算法都需要大量环境交互，学习率、折扣因子、探索系数、奖励权重和网络规模都会影响最终结果。若参数选择不当，模型可能训练缓慢、奖励震荡或形成不安全策略。因此，实验部分不仅要报告最终模型结果，也应记录训练步数、场景设置和评估指标，保证研究具有可复现性。

综合来看，深度强化学习为无人车避障提供了一条有效技术路线，但更成熟的系统应将学习策略、传统规划、安全约束和真实感知结合起来。本文毕业设计完成的是其中的基础环节：在可控二维环境中验证 PPO 与 DQN 的避障能力差异，说明 PPO 在当前任务中更稳定、更安全、更高效。这一结论既来源于外文资料中的算法分析，也得到了本文实验结果的支持。

三、原文出处

[1] Cimurs R, Lee J H, Suh I H. Goal-Oriented Obstacle Avoidance with Deep Reinforcement Learning in Continuous Action Space. Electronics, 2020, 9(3):411. <https://www.mdpi.com/2079-9292/9/3/411>

[2] Zhu W, Gao X, Wu H, et al.. Design of Multimodal Obstacle Avoidance Algorithm Based on Deep Reinforcement Learning. Electronics, 2025, 14(1):78.
<https://www.mdpi.com/2079-9292/14/1/78>

译文中文汉字统计：约 10228 字。

注：若学院要求按英文词数核算，请以所附英文原文 PDF 的正文词数为准；本译文正文按中文汉字统计已超过 10000 字。