

软件工程设计说明书

1、引言

1.1 标识

SRS适用范围：个人与小型团队

标识号：AITURN001

标题：大模型交叉咨询系统

版本号：V1.0

发行号：Alpha001（内测版）

1.2 系统概述

为了能通过ai获取正确精准而快速的回复，我们决定制作一个轻量化的大语言模型交叉咨询系统，能通过多个大语言模型交叉对问题进行优化和确定。

1.3 文档概述

本文档是大模型交叉编辑系统的软件设计说明书（SDS），旨在通过多个大语言模型交叉对问题进行优化和确定。文档围绕“智能场景驱动”的核心设计理念，详细阐述系统架构、模块设计、数据模型及接口规范，覆盖用户需求，历史会话保存等核心功能

1.4 基线

本文档的设计基线是《GBT8567—2006计算机软件文档编制规范》

2、引用文件

[1] GBT8567—2006计算机软件文档编制规范. 2006

[2] Y.Daniel Liang著李娜译, JAVA语言程序设计. 北京：机械工业出版社 2012

[3] 刘先锋，数据库系统原理与应用。 武汉：华中科技大学出版社 2012

3、CSCI级设计决策

3.1 输入输出设计决策

输入方面：系统接受用户以文本形式输入的各类问题或指令。用户通过软件的交互界面，直接输入自然语言文本。同时，为了实现与其他系统的交互，预留标准化 API 接口，可接收其他系统以 JSON 或 XML 格式封装的文本数据请求，实现跨系统的问答功能调用。与用户的交互接口设计遵循简洁易用原则，支持快捷键输入和粘贴输入等便捷操作方式。

输出方面：系统输出为优化后的大模型回答文本。通过交互界面直接展示给用户，输出内容采用清晰的排版格式，区分问题和回答部分。对于通过 API 接口接入的其他系统，按照约定的数据格式（如 JSON）返回结构化的回答数据，包含原始大模型回答和二次优化后的内容。此外，在输出中，若涉及历史记录相关操作（如查看历史问答），也以结构化文本或列表形式展示在交互界面特定区域。

3.2 行为响应设计决策

输入响应：当用户输入问题后，系统会同时将问题发送至接入的多个大模型。为每个大模型设置合理的响应超时时间（如 30 秒），若某个大模型在规定时间内未返回结果，则跳过该模型，继续等待其他模型响应。接收到大模型返回的回答后，结合前导语对回答内容进行二次优化，优化过程包括语句通顺性调整、内容补充完善、重点信息突出等操作。

性能特性：系统整体响应时间目标控制在用户可接受范围内，平均响应时间不超过 5 秒（在网络正常、大模型负载合理的情况下）。对于高并发请求，采用异步处理和队列机制，保证请求有序处理，避免系统崩溃。

3.3 数据库 / 数据文件呈现设计决策

系统保存用户的历史问答记录，历史记录以数据库形式存储。在用户交互界面，提供历史记录查看功能，用户可通过时间筛选、关键词搜索等方式快速定位历史问答。历史记录展示为列表形式，每条记录包含提问时间、问题内容和回答内容。数据库设计采用关系型数据库（如 MySQL），通过合理的表结构设计（如用户表、问答记录表等）保证数据的完整性和查询效率。对于历史记录的备份和恢复，采用定期备份策略，备份数据存储在安全的存储设备中，当系统出现数据丢失等异常情况时，可快速恢复历史记录数据。

3.4 安全、保密、私密性需求满足方法

用户隐私保护：严格遵循相关隐私保护法规，不收集用户的个人敏感信息（如身份证号、银行卡号等）。仅记录与问答相关的必要信息，用户的历史问答记录仅对用户本人可见，系统管理员无权随意查看用户历史记录。提供用户数据删除功能，用户可随时删除自己的历史问答记录。。

3.5 其他 CSCI 级设计决策

灵活性：为实现系统的灵活性，采用插件式架构设计接入多个大模型。通过定义统一的大模型接口规范，方便后续新增或替换大模型，只需开发对应的插件即可实现与系统的集成。同时，前导语的设置采用可配置方式，用户或管理员可根据不同的使用场景和需求，灵活调整前导语内容，实现对大模型回答优化方向的控制。

可用性：系统提供友好的用户交互界面，界面设计符合用户操作习惯，提供清晰的操作指引和提示信息。设置系统状态监控功能，实时监测系统的运行状态（如服务器负载、大模型连接状态等），当系统出现异常时，及时通过邮件、短信等方式通知管理员进行处理。此外，提供在线帮助文档和客服支持渠道，方便用户在使用过程中遇到问题时获取帮助。

可维护性：采用模块化设计思想，将系统划分为不同的功能模块（如大模型接入模块、回答优化模块、历史记录管理模块等），每个模块具有独立的功能和清晰的接口，便于开发和维护。在代码编写过程中，遵循良好的编码规范和注释规范，提高代码的可读性。定期对系统进行代码审查和性能优化，及时修复发现的问题和漏洞，保证系统的稳定运行。

4、CSCI体系结构设计


4.1 体系结构

程序 (模块) 划分


模块名称	标识符	功能描述
大模型管理模块	LLM	封装多个大模型 API 接口，实现并发调用、超时控制、错误处理等功能
菜单管理模块	Menu	保存用户交互的所有页面
历史记录保存模块	Saving	负责问答记录的存储、查询、删除及备份恢复
设置模块	Setting	管理系统参数（如大模型 API 密钥、前导语模板、超时设置等），支持动态加载配置

模块名称	标识符	功能描述
用户交互模块	Main	处理用户输入输出，提供问答界面、历史记录查看、系统配置等交互功能

程序 (模块) 层次结构关系



4.2 静态关系（组成结构）



4.3 用途与需求分配和硬件资源使用

大模型接入插件框架：实现多模型并发调用，满足需求 R-LLM-001（支持至少 3 个大模型接入）和设计决策 D-LLM-002（插件式架构）

历史记录数据库：存储问答历史，满足需求 R-HIST-001（支持 10 万条以上记录存储）和设计决策 D-DB-001（AES 加密存储）

处理器资源

- **需求覆盖：**满足 R-PERF-001（并发处理 ≥ 10 请求 / 秒）
- **假设条件：**最坏情况为 10 个并发请求同时调用 3 个大模型
- **使用数据**
 - 单请求处理 CPU 占用：约 5%（Intel i5-10400）
 - 并发峰值占用： $\leq 50\%$ （预留 50% 资源用于系统开销）
- **度量单位：**CPU 利用率百分比

内存资源

- **需求覆盖：**满足 R-PERF-002（单节点支持 512MB 内存）
- **使用数据**
 - 单请求内存占用：约 20MB（含模型响应缓存）
 - 并发峰值内存： $\leq 200\text{MB}$ （10 并发）
- **特殊考虑：**使用内存池管理缓存，避免频繁 GC 开销

4.4 执行概念

4.4.1 动态交互流程

用户输入阶段：用户通过 UI 模块输入问题，

模型调用阶段：

- 大模型接入模块通过线程池（最大线程数 = 模型数量）并发调用各 API
- 每个调用线程设置超时控制，超时则跳过该模型

回答优化阶段：收集所有有效响应，按前导语规则合并优化

记录存储阶段：历史记录模块将问答数据加密后写入数据库

4.4.2 状态转换图



4.5 接口设计

接口名称	接口实体
用户交互接口	UI 模块与用户
大模型 API 接口	接入模块与外部大模型服务
数据库接口	历史记录模块与数据库

5、注解

术语	定义
CSCI	计算机软件配置项（Computer Software Configuration Item），指系统中可标识的软件实体
SCI	软件配置项（Software Configuration Item），CSCI 的组成部分
前导语	用于引导大模型生成特定风格回答的提示文本，支持变量替换与模板化配置
插件式架构	通过定义标准接口实现功能模块动态加载的设计模式，便于扩展新的大模型接入
并发调用	同时向多个大模型发送请求的机制，通过线程池管理资源分配与超时控制